

Estudio de Técnicas de Aprendizaje Automático usando Sobremuestreo de Datos

Aarón Zeballo

Tutora: Dra. Andrea Rey


13 de julio de 2026

Universidad Nacional de Hurlingham

Planteamiento del Problema

Desbalanceo de Clases

- Los correos legítimos son la inmensa mayoría; las amenazas, la minoría.
- Para simular un entorno real crítico, se submuestreó artificialmente al 5 % de spam.



Métodos Utilizados

Conjunto de Datos (Spambase)

Dataset público estructurado con 57 características predictoras continuas extraídas mediante procesamiento de texto:

Familia de Variables	Atributos	Ejemplo / Unidad
Frecuencia de palabras	48	word_freq_free (%)
Frecuencia de caracteres	6	char_freq_\$ (%)
Secuencia de mayúsculas	3	capital_run_length_total (Con- teo Absoluto)
Variable Objetivo	1	Legítimo (0) o Spam (1)

- **Problema de Escalas:** Las variables que miden frecuencia de palabras están en porcentajes (0 a 5 %), mientras que la secuencia de mayúsculas representa un conteo absoluto (llegando a miles).
- **Consecuencia:** SVM sufre mucho en su calidad predictiva dando atención casi exclusiva a las variables de mayusculas.
- **Solución (StandardScaler):**
 - Transforma las variables para tener Media = 0 y Varianza = 1.
 - Ajustado exclusivamente sobre datos de entrenamiento para evitar Data Leakage.
 - Restaura la capacidad del algoritmo para evaluar todas las variables.

Técnicas de sobremuestreo

Synthetic Minority Over-sampling Technique

- Algoritmo estándar en la industria para la creación de datos sintéticos.
- Analiza instancias de la clase minoritaria (spam) y busca a sus k vecinos más cercanos ($k = 5$).
- Genera nuevos correos sintéticos trazando una línea recta entre el ejemplo original y el vecino elegido al azar.
- **Desventaja:** Genera datos uniformemente para toda la clase minoritaria, lo que puede si la línea recta cruza por zonas de correos legítimos.

Adaptive Synthetic Sampling

- Evolución que corrige el problema de SMOTE prestando mucha atención a las fronteras de decisión.
- Calcula la densidad de probabilidad para definir qué tan "difícil" de aprender es cada instancia de spam.
- **Concéntra la creación de datos artificiales únicamente alrededor de los correos más difíciles** de clasificar.
- **Ventaja:** Evita generar información innecesaria en zonas seguras que los modelos ya pueden separar fácilmente.

Geometric SMOTE

- Evolución geométrica directa para evitar la creación de ruido.
- En lugar de generar muestras sobre líneas rectas, define una **zona esférica** alrededor de los correos minoritarios originales.
- Su precisión radica en calcular primero la distancia exacta hacia el ejemplo legítimo más cercano, **restringiendo el radio** de la esfera para nunca cruzar esa frontera.
- Resulta en un sobremuestreo variado pero sumamente seguro, sin invadir el territorio legítimo.

Método Híbrido (Edited Nearest Neighbours)

- Combina la creación inteligente (ADASYN) con una rigurosa etapa de limpieza algorítmica final (ENN).
- **Fase 1:** ADASYN inyecta nuevos datos sintéticos en las zonas fronterizas más difíciles.
- **Fase 2:** El algoritmo ENN revisa todo el conjunto ampliado evaluando a los 3 vecinos más cercanos de cada observación.
- Si detecta que una instancia está rodeada por la clase contraria, asume que confundirá al clasificador y la elimina por completo.

Modelos de Clasificación

Arbol de decision

Bosques Aleatorios

Máquinas de Soporte Vectorial

Resultados


Justificación de la Proporción Óptima

Se evaluaron múltiples niveles de sobremuestreo con para encontrar el equilibrio ideal:

Proporción (Legítimo/Spam)	Precision	Recall	F1-Score
50/50	0,5556	0,8621	0,6757
60/40	0,6098	0,8621	0,7143
70/30	0,6757	0,8621	0,7576
80/20	0,6471	0,7586	0,6984

La relación **70/30** aumenta el F1-Score sin sacrificar significativamente la detección de amenazas (Recall).


Resultados con Proporción Óptima (70/30)



Métricas Destacadas:

- **Random Forest (G-SMOTE):** Alcanzó la mayor Precision (**0,84**) y el mejor F1-Score (**0,80**).
- **SVM (ADASYN):** Logró la mayor tasa de captura de amenazas con un Recall de **0,86**.

Comparativa: Sobremuestreo vs. Datos Originales



Impacto del Sobremuestreo (SVM + ADASYN):

- Al aplicar ADASYN (70/30), el modelo eleva su **Recall a 0,86**.
- Se aproxima fuertemente al rendimiento del modelo entrenado con el dataset original Recall de 0,89, superando por completo al modelo desbalanceado.

Conclusiones

Conclusiones: Los Mejores resultados

No existe un sobremuestreo perfecto; el ganador depende de la prioridad buscada.

1. Prioridad: Minimizar Falsos Positivos

- **Ganador:** Random Forest + G-SMOTE
- Gracias a la restricción esférica, alcanzó la mejor Precision (0,84) y el mejor F1-Score (0,80) del estudio.

2. Prioridad: Máxima Detección

- **Ganador:** SVM (Umbral ajustado a 0.2) + ADASYN
- Enfoque ultra agresivo. Logró un sobresaliente Recall de 0,86, detectando casi todas las amenazas a costo de permitir más falsos positivos.

Conclusiones: Sobremuestreo vs. Datos Reales

- **Comparativa Final:** Se evaluó el método de sobremuestreo ganador contra el conjunto *SpamBase original* el cual poseía naturalmente un 40 % de spam.
- **Superioridad Original vs. Recuperación:** Lógicamente, los datos originales demostraron una ligera superioridad (Recall de 0,89).
- Sin embargo, el modelo entrenado con **ADASYN logró un excepcional Recall de 0,86** partiendo desde un desbalance casi total del 5 %.
- **Reflexión Final:** Esto demuestra que las técnicas de sobremuestreo son herramientas altamente eficaces y robustas, capaces de recuperar casi por completo la capacidad predictiva de algoritmos limitados por la carencia de observaciones.

¡Muchas gracias!