

# Estudio de Técnicas de Aprendizaje Automático usando Sobremuestreo de Datos

---

Aarón Zeballo

Tutora: Dra. Andrea Rey

8 de octubre de 2026

Universidad Nacional de Hurlingham

# Planteamiento del Problema


---

# Correo No Deseado (Spam)

- **Evolución Histórica:** Lo que comenzó como publicidad molesta en los 90 evolucionó a una de las principales herramientas del cibercrimen moderno.
- **Impacto Actual:**
  - Saturación de infraestructura y daño económico a nivel corporativo.
  - Riesgo de seguridad y estafas para usuarios.
- **El rol del Machine Learning:** Los filtros basados en reglas estáticas quedaron obsoletos. Se requieren algoritmos capaces de detectar patrones.
- **El Gran Desafío:** Entrenar estos modelos presenta un problema debido a los correos: el desbalanceo entre los legítimos y los de *spam*.

# Desbalanceo de Clases

- Los correos legítimos son la mayoría; las amenazas, la minoría.
- Para simular un entorno real, se eliminaron instancias de la clase *spam* hasta alcanzar un porcentaje del 5 %.



# Conjunto de Datos (Spambase)

Dataset público estructurado con 57 características predictoras continuas extraídas mediante procesamiento de texto:

| Familia de Variables     | Atributos | Ejemplo / Unidad                                |
|--------------------------|-----------|-------------------------------------------------|
| Frecuencia de palabras   | 48        | word_freq_free (%)                              |
| Frecuencia de caracteres | 6         | char_freq_\$ (%)                                |
| Secuencia de mayúsculas  | 3         | capital_run_length_total (Con-<br>teo Absoluto) |
| <b>Variable Objetivo</b> | <b>1</b>  | Legítimo (0) o Spam (1)                         |

# Métodos Utilizados

---

- **Problema de Escalas:** Las variables de frecuencia de palabras están en porcentajes (0 a 5 %), mientras que la secuencia de mayúsculas es un conteo absoluto (llegando a miles).
- **Consecuencia:** SVM sufre en su calidad predictiva dando atención casi exclusiva a las mayúsculas.
  - Transforma las variables para tener Media = 0 y Varianza = 1.
  - Ajustado exclusivamente sobre datos de entrenamiento para evitar Data Leakage.
  - Restaura la capacidad del algoritmo para evaluar todas las variables.

# Técnicas de sobremuestreo

---

## Synthetic Minority Over-sampling Technique

- Algoritmo estándar en la industria para la creación de datos sintéticos.
- Analiza de a una las instancias de la clase minoritaria.
- Para cada instancia, busca a sus  $k$  vecinos más cercanos (en este trabajo se utilizó  $k = 5$ ).
- Dependiendo de la cantidad de muestras sintéticas que deba generar para alcanzar el porcentaje deseado entre clases, elige aleatoriamente uno o más vecinos para trazar conexiones.


# SMOTE: Funcionamiento Matemático

La generación del nuevo dato sintético ( $\mathbf{x}_{\text{nuevo}}$ ) se realiza mediante interpolación lineal:

$$\mathbf{x}_{\text{nuevo}} = \mathbf{x}_i + \lambda(\mathbf{x}_{\text{vecino}} - \mathbf{x}_i) \quad (1)$$

- $\mathbf{x}_i$ : La instancia original.
- $\mathbf{x}_{\text{vecino}}$ : El vecino seleccionado al azar.
- $\lambda$ : Un número aleatorio entre 0 y 1 que ubica al nuevo dato en un punto intermedio de la línea recta que los une.
- **Desventaja Principal:** Crea muestras ciegamente. Si la línea matemática cruza por una zona ocupada por la clase mayoritaria, generará datos sintéticos ruidosos que perjudicarán al modelo.

# SMOTE: Representación Visual



## Geometric SMOTE: Superando las limitaciones lineales

- El problema de SMOTE: Al trazar líneas rectas, existe un alto riesgo de invadir regiones que ya están fuertemente pobladas por la clase mayoritaria.
- La solución de G-SMOTE: Propone un enfoque geométrico. Donde los datos sintéticos se crean dentro de una esfera.

## G-SMOTE: Zona Esférica de Generación


- En lugar de generar muestras a lo largo de una línea , G-SMOTE define una zona esférica alrededor de cada instancia original de la clase minoritaria.
- Las nuevas muestras sintéticas pueden aparecer en cualquier punto aleatorio dentro de esa burbuja protectora.
- Al contar con todo el volumen de la esfera, se logra crear una diversidad de ejemplos mucho mayor para enriquecer el conjunto de entrenamiento.

## G-SMOTE: Restricción del Radio

¿Cómo se asegura G-SMOTE de que la esfera no sea tan grande que termine invadiendo a la clase mayoritaria?

- Primero, calcula la distancia exacta hacia el dato de la clase mayoritaria más cercano.
- Una vez calculada esa distancia, la utiliza como un límite para restringir el radio máximo de la esfera.
- Esto permite expandir la frontera de la clase minoritaria con garantía de nunca cruzar la barrera.

## G-SMOTE: Representación Visual



## Adaptive Synthetic Sampling: Enfoque en la Dificultad

- El problema de SMOTE/G-SMOTE: Distribuyen el esfuerzo de generación de datos de forma relativamente uniforme. Crean la misma cantidad de datos artificiales tanto para un dato aislado como para uno extremadamente difícil de clasificar.
- La solución de ADASYN: Concentrar el esfuerzo del algoritmo de forma adaptativa exclusivamente en la frontera de decisión (la zona donde ambas clases se mezclan fuertemente).
- Por lo tanto, ADASYN es superior en casos donde el verdadero problema radica en aprender a separar fronteras difusas o altamente solapadas, evitando inflar de datos innecesarios a las regiones que ya son "seguras".

# ADASYN: Función de Densidad


El objetivo principal del algoritmo es identificar automáticamente qué datos de la clase minoritaria son los que están causando más confusiones al modelo de aprendizaje.

- Para lograrlo, ADASYN primero examina los vecinos de cada observación minoritaria.
- Calcula una función de densidad de probabilidad observando cuántas instancias de la clase mayoritaria están rodeando a cada dato.
- Mientras más datos de la clase mayoritaria lo rodeen, mayor es la densidad calculada y, por ende, mayor es el riesgo de que en el futuro haya una clasificación incorrecta en esa zona.

Con la información de las densidades analizada, el algoritmo ejecuta la generación de datos de forma asimétrica:

- Establece un ratio de dificultad de aprendizaje para cada instancia original.
- Una observación minoritaria aislada y fácil de clasificar recibirá un ratio bajo (casi no se crearán datos sintéticos a su alrededor).
- Una observación minoritaria dentro de la zona de la clase mayoritaria recibirá un ratio muy alto.

# ADASYN: Representación Visual



## ADASYN + Edited Nearest Neighbours: La necesidad de limpieza

- El problema de ADASYN: Al forzar la inyección de datos justo en la frontera conflictiva, existe un gran riesgo de empeorar el aprendizaje y generar una zona llena de clases solapadas que confundan en clasificador.
- La solución del método híbrido: Complementar la creación de ADASYN con un algoritmo de submuestreo de limpieza llamado ENN (*Edited Nearest Neighbours*).
- Por lo tanto, la combinación permite generar un volumen necesario de datos en las fronteras críticas y luego limpiar las muestras que podrían ser perjudiciales para la clasificación.

## ADASYN + ENN: Fase 1 (Generación)

El proceso híbrido comienza apoyándose estrictamente en ADASYN para resolver el déficit principal de información:

- Se ejecuta el algoritmo ADASYN sobre el conjunto desbalanceado.
- Se inyectan las nuevas instancias minoritarias sintéticas enfocándose en los casos más difíciles y solapados.
- Al finalizar esta etapa, se cuenta con un conjunto temporalmente ampliado que solucionó el desbalanceo, pero que muy probablemente cuenta con una frontera de decisión ruidosa.

## ADASYN + ENN: Fase 2 (Limpieza ENN)

Una vez ampliado el conjunto, ENN entra en acción de forma quirúrgica para corregir el ruido generado:

- El algoritmo analiza cada una de las observaciones (tanto originales como sintéticas) del nuevo conjunto expandido.
- Para cada dato, evalúa la etiqueta de sus 3 vecinos más cercanos.
- Si detecta que la mayoría de los vecinos de una instancia pertenecen a la clase contraria, el algoritmo asume que es una anomalía que confundirá al modelo predictivo.
- En tal caso, elimina la observación por completo, obteniendo un conjunto final no solo sobremuestreado, sino limpio.

# Modelos de Clasificación

---

# Modelos de Clasificación: Parámetros

## Árbol de Decisión

**Criterio de partición:**  
gini

**Profundidad máxima:**  
Ninguna

**Muestras mín. dividir:**  
2

**Muestras mín. hoja:**  
1

## Random Forest

**Criterio de partición:**  
gini

**Cantidad de árboles:**  
100

**Caract. división:**  
Raíz cdra.

**Muestras mín. dividir:**  
2

## SVM

**Regularización (C):**  
1.0

**Tipo de Kernel:**  
rbf

**Coficiente Kernel:**  
scale

**Umbral Decisión:**  
0.2

*\* Se utilizaron los parámetros por defecto de `scikit-learn`, únicamente cambiando manualmente el umbral de decisión del SVM a 0,2*

# Resultados

---


## Justificación de la Proporción Óptima

Se evaluaron múltiples niveles de sobremuestreo para encontrar el equilibrio ideal:

| Proporción (Legítimo/Spam) | Precision     | Recall        | F1-Score      |
|----------------------------|---------------|---------------|---------------|
| 50-50                      | 0,5556        | 0,8621        | 0,6757        |
| 60-40                      | 0,6098        | 0,8621        | 0,7143        |
| <b>70-30</b>               | <b>0,6757</b> | <b>0,8621</b> | <b>0,7576</b> |
| 80-20                      | 0,6471        | 0,7586        | 0,6984        |


La relación 70-30 aumenta el F1-Score sin sacrificar Recall.

# Resultados con Proporción Óptima (70-30)



- **Random Forest (G-SMOTE):** Alcanzó la mayor Precisión (0,84) y el mejor F1-Score (0,80).
- **SVM (ADASYN):** Logró el mayor Recall, con un valor de 0,86.

# Comparativa: Sobremuestreo vs. Datos Originales



## Impacto del Sobremuestreo (SVM + ADASYN):

- Al aplicar ADASYN (70-30), el modelo eleva su Recall a 0,86.
- Se aproxima fuertemente al rendimiento del modelo entrenado con el dataset original (Recall de 0,89), superando ampliamente al desbalanceado.

# Conclusiones

---

# Conclusiones: Los Mejores resultados

No existe un sobremuestreo perfecto; el ganador depende de la prioridad buscada.

## 1. Prioridad: Minimizar Falsos Positivos

- **Ganador:** Random Forest + G-SMOTE
- Gracias a la restricción esférica, alcanzó la mejor Precision (0,84) y el mejor F1-Score (0,80) del estudio.

## 2. Prioridad: Máxima Detección

- **Ganador:** SVM (Umbral ajustado a 0.2) + ADASYN
- Enfoque si se prioriza detectar amenazas. Logró un Recall de 0,86, detectando casi todas las amenazas a costo de permitir más falsos positivos.

## Conclusiones: Sobremuestreo vs. Datos Reales

- **Comparativa Final:** Se evaluó el método de sobremuestreo ganador contra el conjunto *SpamBase original* el cual poseía naturalmente un 40 % de spam.
- **Original vs Sobremuestreado:** Lógicamente, los datos originales demostraron una ligera superioridad (Recall de 0,89).
- Sin embargo, el modelo entrenado con ADASYN logró un Recall de 0,86 partiendo desde un desbalance del 5 %.
- **Reflexión Final:** Esto demuestra que las técnicas de sobremuestreo son herramientas eficaces y robustas, capaces de recuperar casi por completo la capacidad predictiva de algoritmos limitados por la carencia de observaciones.

**¡Muchas gracias!**