

Estudio de Tecnicas de Aprendizaje Automatico Supervisado usando Sobremuestreo de Datos

Autor: Aarón Zeballo
Tutora: Dra. Andrea Rey

Universidad Nacional de Hurlingham (UNAHUR)



Índice general

Índice de Figuras

Índice de Tablas

Resumen

Capítulo 1

Introducción

El correo no deseado, comúnmente conocido como *spam*, representa uno de los mayores desafíos globales en el ámbito de las telecomunicaciones y la ciberseguridad. Diariamente se envían miles de millones de estos mensajes, los cuales no solo generan pérdidas millonarias por la saturación de servidores web y caídas de productividad, sino que constituyen la principal vía para ataques de *phishing*, estafas y distribución de *malware*. La idea de este trabajo es encontrar una técnica de aprendizaje automático para poder realizar predicciones sobre si un correo electrónico es una amenaza o un mensaje legítimo. Uno de los mayores obstáculos en la detección de *spam* es el desequilibrio de la información: los correos maliciosos representan una pequeña fracción frente a la abrumadora mayoría de correos normales. Los modelos tradicionales de clasificación tienden a ignorar esta minoría, volviéndose ineficientes. El objetivo general de este trabajo es comparar el rendimiento de diversas técnicas de aprendizaje automático, combinadas con métodos de balanceo de datos, con el fin de encontrar la arquitectura que presente el mejor desempeño al aplicarse sobre un conjunto de datos de correos electrónicos. Se expondrán las técnicas utilizadas y las métricas para evaluar la calidad de los clasificadores y mostrar qué técnicas resulta más adecuadas.

1.1 Motivación

El proceso de identificación y filtrado de correos no deseados debe ser altamente confiable, ya que un error de clasificación puede resultar en la vulneración de la seguridad de un usuario o, por el contrario, en la pérdida de un correo legítimo enviándolo por error a la papelera. El propósito de este trabajo es contribuir a agilizar y asegurar dicho proceso, identificando técnicas algorítmicas que puedan ser utilizadas por los sistemas de seguridad informática como herramientas robustas para el pre-diagnóstico de amenazas. No solo resulta fundamental la posibilidad de obtener filtros más eficaces, sino también la de reconocer cómo la inyección artificial de datos sintéticos resulta indispensable para obligar a los algoritmos predictivos a dar importancia a aquellas amenazas críticas que, de otro modo, pasarían desapercibidas por encontrarse en minoría.

1.2 Estado del Arte

1.3 Conjunto de Datos

Para el desarrollo de este trabajo se utilizó el conjunto de datos público *Spam Email Classification*. Este conjunto de datos incluye anuncios de productos, mensajes de estafa, cadenas de mensajes y contenido no apropiado. Por otro lado, los correos legítimos provienen del ámbito laboral y personal de los

recolectores originales.

El conjunto de datos está estructurado en 58 columnas, divididas en 57 variables predictoras continuas y 1 variable objetivo. Las características extraídas de cada correo electrónico se dividen en tres grandes grupos:

- **Frecuencia de palabras (48 atributos):** Miden el porcentaje de aparición de palabras específicas que suelen ser comunes en el spam.
- **Frecuencia de caracteres (6 atributos):** Miden el porcentaje de aparición de ciertos caracteres especiales (como signos de exclamación o de dólar) respecto a la cantidad total de caracteres en el mensaje.
- **Secuencias de letras mayúsculas (3 atributos):** Cuantifican el uso ininterrumpido de mayúsculas, un rasgo frecuentemente asociado al spam. Estos tres atributos representan:
 - El promedio de longitud de las secuencias de letras mayúsculas.
 - La secuencia de letras mayúsculas más larga del correo.
 - La suma total de todas las letras mayúsculas presentes.

Finalmente, la última columna corresponde a la variable de clasificación (*class*), la cual toma el valor de 1 si el mensaje fue considerado (*spam*) o 0 si se trata de un correo legítimo.

Capítulo 2

Metodología

2.1 Preparación de los Datos

El trabajo comenzó con el procesamiento del conjunto de datos original. Como el objetivo era estudiar el comportamiento de los algoritmos frente a clases desbalanceadas, se eliminaron aleatoriamente instancias de la clase positiva hasta que los correos de spam representaran únicamente el 5 % del total.

A continuación, el conjunto de datos se dividió en un 80 % para el entrenamiento de los modelos y el 20 % restante para las pruebas. Para evitar la filtración de información, la estandarización de las variables numéricas se realizó ajustando la herramienta **StandardScaler** exclusivamente con los datos de entrenamiento, transformando luego ambos conjuntos. Este paso es necesario para que los clasificadores basados en distancias (como SVM) funcionen correctamente.

2.2 Balanceo y Entrenamiento

Para resolver el problema del desbalanceo durante el entrenamiento, se utilizaron diferentes técnicas de sobremuestreo. Primero se evaluaron los datos originales sin balancear para tener una base de comparación. Luego, se aplicaron los siguientes algoritmos para generar datos sintéticos:

- **SMOTE**: Crea nuevas muestras interpolando líneas entre los ejemplos de la clase minoritaria y sus vecinos.
- **G-SMOTE**: Genera muestras dentro de una zona circular alrededor de cada correo de clase positiva.
- **ADASYN**: Genera más cantidad de muestras sintéticas en la frontera difícil donde las clases se mezclan.
- **ADASYN + ENN (Híbrido)**: Aplica ADASYN y luego usa el algoritmo de limpieza ENN para borrar el ruido en la frontera.

En lugar de balancear los datos a una proporción perfecta de 50/50 (lo cual causaba una caída en la Precisión debido al aumento de falsos positivos), se trabajó con una relación aproximada de 70/30 en el entrenamiento, preservando un mejor equilibrio en el modelo.

Con estos datos preparados, se entrenaron tres modelos de clasificación: Random Forest, Máquinas de Soporte Vectorial (SVM) y Árbol de Decisión, manteniendo una semilla aleatoria fija para asegurar la reproducibilidad. En el caso particular de SVM, se comprobó experimentalmente que ajustar el umbral de decisión a 0.2 mejoraba de forma significativa la detección de la clase minoritaria sin incurrir en sobreajuste.

Finalmente, el rendimiento de todos los algoritmos se midió sobre el conjunto de prueba (20 % reservado). Dado que la (*Accuracy*) suele ser engañosa en datos desbalanceados, la evaluación se centró en métricas más rigurosas: (*Recall*) para conocer el porcentaje de spam atrapado, (*Precision*) para medir la confiabilidad de las alertas, y *F1-Score* como métrica unificadora.

Capítulo 3

Resultados y discusión

3.1 Análisis de Rendimiento frente al Desbalanceo

La primera fase del experimento consistió en evaluar el desempeño de los algoritmos sobre el conjunto de datos desbalanceado, sin aplicar técnicas de sobremuestreo. Como era de esperarse, los modelos priorizaron el *Accuracy* clasificando casi todo como clase mayoritaria. El modelo base permitía que casi la mitad del spam ingresara sin ser detectado, confirmando la vulnerabilidad de los clasificadores estándar ante un desbalanceo del 5 %. Al aplicar las técnicas de generación de datos sintéticos, los tres algoritmos reaccionaron de manera diferente. ADASYN demostró ser la técnica de balanceo superior, superando consistentemente a SMOTE y G-SMOTE en todos los casos, por lo que el análisis profundo se centró en sus resultados:

- **Árbol de Decisión:** Demostró ser el algoritmo más débil. Incluso con los datos balanceados mediante ADASYN, mostrando que el modelo no es eficiente a la hora de distinguir en la frontera entre correos legítimos y de spam logrando un recall de 58.6 %.
- **Random Forest:** Exhibió un comportamiento superior. Al ser entrenado con los datos de ADASYN, elevó su *Recall* al 75.8 % manteniendo un altísimo *Precision* del 81.4 % (logrando el *F1-Score* global más alto del experimento, 0.7857). Esto lo consolida como un clasificador extremadamente seguro y confiable, ideal si la prioridad del sistema es evitar que correos legítimos terminen en la papelera.
- **SVM (con umbral optimizado a 0.2):** Fue el algoritmo que más se benefició de la inyección geométrica de ADASYN en la frontera. Logró la mejor tasa de detección de amenazas de todo el experimento, alcanzando un *Recall* del 86.2 %. Superó a Random Forest en este aspecto crítico, aunque a costa de sacrificar algo de *Precision* (71.4 %).

3.2 Análisis de la Técnica Híbrida (ADASYN + ENN)

Una vez Elegido ADASYN como el modelo superior para el sobemuestreo de datos en este conjunto de datos se probó con una técnica moderna que expande ADASYN limpiando la inyección de datos revisando los vecinos más cercanos a los datos sintéticos. Todos los algoritmos sufrieron una caída en su rendimiento bajo esta limpieza. En el caso de SVM, la Precisión se desplomó del 71.4 % al 62.5 %, y en Random Forest cayó del 81.4 % al 73.3 %. Esto se explica porque en el filtrado de spam real, la frontera es intrínsecamente difusa (hay correos legítimos que usan palabras típicas de spam). ADASYN generó muestras valiosas en estos casos ambiguos, pero ENN las borró al considerarlas ruido". Esto privó a todos los modelos de información crucial en la frontera, Llevando a una caída de los resultados frente a la Técnica clásica.




Figura 3.1: Impacto de las técnicas de sobremuestreo en las métricas de Accuracy y Precision para los distintos modelos evaluados.




Figura 3.2: Impacto de las técnicas de sobremuestreo en las métricas de F1-Score y Recall. Se observa la superioridad de ADASYN en la métrica de Recall para el modelo SVM.

Capítulo 4

Conclusiones